

FICHE DE TD 3/3 • DIFFICILE

Mathématiques • Tle C D E TI

Statistiques à deux variables

Organisation et gestion des données

Consignes : Les exercices sont indépendants. Toute trace de recherche, même incomplète, sera valorisée. La rigueur du raisonnement et la qualité de la rédaction entrent pour moitié dans la note.

EXERCICE 1 Comparaison d'ajustements et analyse de la corrélation

On étudie l'évolution du rendement y (en quintaux/hectare) d'une culture en fonction de la dose d'engrais x (en kg/hectare). Les résultats de 10 parcelles expérimentales sont consignés ci-dessous :

x	20	30	40	50	60	70	80	90	100	110
y	25	30	38	42	48	52	58	60	65	68

1. Construire le nuage de points dans un repère orthonormé (échelle : 1 cm pour 10 kg sur l'axe des abscisses, 1 cm pour 5 qx/ha sur l'axe des ordonnées). Déterminer les coordonnées du point moyen $G(\bar{x}, \bar{y})$ et le placer.
2. Méthode de Mayer : Diviser le nuage en deux sous-groupes de même effectif (premiers 5 et derniers 5 points). Déterminer les points moyens G_1 et G_2 de ces sous-groupes. Établir l'équation de la droite de Mayer M passant par G_1 et G_2 . Tracer M .
3. Méthode des moindres carrés : Calculer les sommes $\sum x_i$, $\sum y_i$, $\sum x_i^2$, $\sum x_i y_i$, $\sum y_i^2$. En déduire la covariance $\text{cov}(X, Y)$, les variances $V(X)$ et $V(Y)$, puis le coefficient de corrélation linéaire r . Interpréter sa valeur.
4. Déterminer les équations des droites de régression de Y en X ($d_{y/x}$) et de X en Y ($d_{x/y}$). Vérifier qu'elles se coupent en G . Tracer $d_{y/x}$ sur le même graphique que M .
5. Comparer les pentes de M et $d_{y/x}$. Dans quel cas la méthode de Mayer fournit-elle une estimation biaisée de la pente théorique ? Justifier.
6. Prédire le rendement pour une dose de 75 kg/ha en utilisant $d_{y/x}$. Calculer le résidu pour le point (70; 52). Que représente la somme des carrés des résidus (SCR) ? Donner sa valeur.
7. On décide de changer d'unité pour x : $x' = x/10$ (dose en 10 kg/ha). Comment se transforment l'équation de $d_{y/x}$, la covariance, le coefficient de corrélation et le coefficient de détermination R^2 ? Démontrer vos affirmations.

EXERCICE 2 Propriétés géométriques et algébriques des droites de régression

Soit une série statistique à deux variables $(x_i, y_i)_{i=1..n}$ avec $V(X) > 0$ et $V(Y) > 0$. On note $d_{y/x}$ la droite de régression de Y en X (équation $y = a_1x + b_1$) et $d_{x/y}$ la droite de régression de X en Y (équation $x = a_2y + b_2$ ou $y = \frac{1}{a_2}x - \frac{b_2}{a_2}$). On note r le coefficient de corrélation.

1. Démontrer que les droites $d_{y/x}$ et $d_{x/y}$ sont distinctes si et seulement si $|r| \neq 1$. Que se passe-t-il géométriquement si $|r| = 1$?
2. Montrer que le produit des pentes des deux droites de régression (exprimées sous la forme $y = ax + b$) est égal à r^2 . En déduire que les deux droites sont perpendiculaires si et seulement si $r = 0$.
3. Soit θ_1 l'angle orienté de $d_{y/x}$ avec l'axe des abscisses et θ_2 celui de $d_{x/y}$ (exprimée sous forme $y = ax + b$). Exprimer $\tan \theta_1$ et $\tan \theta_2$ en fonction de r, σ_x, σ_y . Montrer que la bissectrice de l'angle formé par les deux droites de régression passant par G a pour pente $\pm \frac{\sigma_y}{\sigma_x}$. Interpréter cette bissectrice dans le cas $r > 0$.
4. On définit la droite passant par G de pente $\frac{\sigma_y}{\sigma_x}$ (droite des "écarts-types"). Montrer que cette droite minimise la somme des carrés des distances orthogonales des points au droit seulement si $r = 1$. Quel est le lien avec l'Analyse en Composantes Principales (ACP)?
5. Question ouverte : On transforme les variables par $X' = aX + b$ et $Y' = cY + d$ ($a, c \neq 0$). Étudier l'effet de cette transformation affine sur : les équations des droites de régression, le coefficient de corrélation r , le coefficient de détermination R^2 , et l'angle entre les deux droites de régression.

EXERCICE 3 Ajustement, prévision et analyse de résidus – Cas d'une série temporelle

Une entreprise suit son chiffre d'affaires mensuel y (en millions de FCFA) sur 12 mois ($x = 1, 2, \dots, 12$). Les données brutes donnent les sommes suivantes : $\sum x_i = 78, \sum y_i = 1560, \sum x_i^2 = 650, \sum x_i y_i = 10500, \sum y_i^2 = 205000$.

1. Calculer $\bar{x}, \bar{y}, V(X), \text{cov}(X, Y), r$. Tester la significativité de la corrélation au seuil $\alpha = 5\%$ (valeur critique de Student pour $n - 2 = 10$ ddl : $t_{0.025} \approx 2.228$). Conclure sur l'existence d'une relation linéaire significative.
2. Déterminer l'équation de la droite de régression $d_{y/x}$. Calculer le coefficient de détermination R^2 et l'interpréter dans le contexte.
3. Calculer les valeurs théoriques $\hat{y}_i$ et les résidus $e_i = y_i - \hat{y}_i$ pour $x = 6$ et $x = 12$, sachant que $y_6 = 125$ et $y_{12} = 155$. Représenter schématiquement le nuage des résidus en fonction de x (ou des $\hat{y}$). Que doit-on observer pour valider l'hypothèse de linéarité et d'homoscédasticité?
4. L'entreprise souhaite prévoir le CA pour le mois 13 ($x = 13$). Calculer cette prévision

$\hat{y}_{13}$. Discuter de la fiabilité de cette prévision (extrapolation). Proposer une formule pour l'intervalle de prévision à 95% (sans calcul numérique, expliciter les termes nécessaires : erreur standard, valeur critique, levier).

5. On suspecte une saisonnalité non modélisée. Proposer une méthode pour détecter cette saisonnalité à partir des résidus. Si une composante saisonnière additive de période 4 est identifiée, comment modifier le modèle de régression pour l'intégrer ? Écrire le nouveau modèle.

EXERCICE 4 Synthèse : Choix du modèle et critique d'une étude

Un étudiant analyse la relation entre la pression artérielle systolique Y (mmHg) et l'âge X (années) sur un échantillon de 50 patients. Il obtient $r = 0,85$ et la droite de régression $y = 0,6x + 90$. Il conclut : "L'âge explique 85% de la variabilité de la pression artérielle ; pour un patient de 80 ans, la pression prévue est 138 mmHg, ce qui est normal."

1. Identifier et corriger les erreurs d'interprétation dans la conclusion de l'étudiant (coefficient de détermination vs corrélation, extrapolation, notion de "normalité" médicale).
2. L'étudiant a calculé r sans vérifier les hypothèses. Lister les 4 hypothèses classiques du modèle linéaire simple (Linéarité, Indépendance, Homoscédasticité, Normalité des résidus). Pour chacune, décrire un outil graphique ou un test permettant de la vérifier.
3. On découvre que deux patients âgés de 90 et 95 ans ont des pressions de 180 et 190 (points aberrants leviers). Qualitativement, comment ces points influencent-ils r , la pente de $d_{y/x}$, et l'interception ? Que devient la prévision pour 80 ans ?
4. Proposer une approche robuste (ex : régression médiane, ou suppression justifiée) pour traiter ces points. Comparer conceptuellement l'estimateur des moindres carrés et l'estimateur de Theil-Sen (pente médiane des pentes par paires) en termes de sensibilité aux valeurs aberrantes et d'efficacité asymptotique.
5. Problème inverse : On ne connaît que $r = 0,8$, $\bar{x} = 50$, $\bar{y} = 120$, $\sigma_x = 10$, et l'équation de $d_{x/y}$: $x = 0,5y - 10$. Retrouver σ_y et l'équation de $d_{y/x}$. Vérifier la cohérence avec la formule $r^2 = a_1 a_2'$ (pentes respectives).